

Efecto de la Tasa de Política Monetaria en las Tasas de Interés del Sector Financiero

Eduar Amaya
Universidad Nacional Autónoma de Honduras
e-mail: eduardamaya@unah.hn

ÍNDICE

I.	Defnición del Problema	2
II.	Preliminares y Notación	2
II-A.	Series de tiempo	2
II-B.	Modelo	3
III.	Resultados	4
III-A.	Primer resultado	4
III-B.	Segundo Resultado	6
III-C.	Tercer Resultado	9
III-D.	Cuarto Resultado	12
	Referencias	15

ÍNDICE DE FIGURAS

1.	Gráfica de la Serie.	4
2.	Variabilidad Estable.	4
3.	Serie Diferenciada una vez.	4
4.	Serie Diferenciada dos veces.	4
5.	Determina el numero de medias móviles	5
6.	Determina el numero de Autore-regresivos	5
7.	Función de Autocorrelación	5
8.	Función de Autocorrelación Parcial	5
9.	Gráfica del Error	6
10.	Gráfica de las Predicciones	6
11.	Representacion de las Series	7
12.	Series Estacionarias	7
13.	Cómo Responde la TIA Ante un Impulso de la TIP.	9
14.	Cómo Responde la TIA Ante un Impulso del IPC.	9
15.	Cómo Responde la TIP Ante un Impulso de la TPM.	9
16.	Cómo Responde la TIP Ante un Impulso del IPC.	9
17.	Representación de las Series	10
18.	Series Estacionarias	10
19.	Cómo Responde la TIA Ante un Impulso de la TPM.	11
20.	Cómo Responde la TIP Ante un Impulso de la TPM.	12
21.	Cómo Responde la TIP Ante un Impulso de la TIA.	12
22.	Cómo Responde la TIP Ante un Impulso del IPC.	12
23.	Representación de las Series	12
24.	Representación de las Series con dos Diferencias	13
25.	Respuestas de las variables ante un Impulso de la TIA	14
26.	Respuestas de las variables ante un Impulso de la TPM	14
27.	Respuestas de las variables ante un Impulso del IPC	14

ÍNDICE DE CUADROS

I.	Criterio AIC	5
II.	Criterio BIC	5
III.	Predicciones	6
IV.	Test de Dickey-Fuller	12
V.	Test de Dickey-Fuller	13
VI.	Número de retardos del modelo VAR	13
VII.	Número de retardos del modelo VAR	13

Efecto de la Tasa de Política Monetaria en las Tasas de Interés del Sector Financiero

Resumen—El resumen no solo hace referencia al trabajo reportado, también sintetiza el trabajo documentado en aproximadamente 200 palabras. Establece el propósito, reporta la información obtenida, provee conclusiones, y recomendaciones. En esencia, resume los puntos principales del estudio de forma adecuada y precisa. Es importante referirse a los resultados principales obtenidos en tiempo pasado al describir el trabajo realizado.

En la introducción se describe de forma concisa pero con un poco más de detalle el trabajo realizado.

En uno de los párrafos de esta sección se hace especial énfasis en la contribución realizada como parte del trabajo reportado, considerando como punto de partida el problema central que motivó el proyecto de investigación y las soluciones obtenidas por el autor del documento como resultado del trabajo de investigación realizado.

Se presentan además descripciones breves del resto de las secciones del documento.

I. DEFINICIÓN DEL PROBLEMA

El objetivo primario de la Política Monetaria es alcanzar y mantener una Tasa de Inflación baja y estable, y lograr un crecimiento económico alrededor de su tendencia de largo plazo.

Esta es la única manera de lograr un crecimiento sostenido que genere empleo y mejore el nivel de vida de la población. Por el contrario, si la economía crece a un ritmo que no es sostenible, tarde o temprano se generará una crisis con consecuencias graves para la economía, deterioro de los indicadores sociales, pérdida de confianza de la población y caídas en la inversión y en el empleo.

En nuestro país no se cuenta con un modelo que ayude a medir el efecto que la tasa de Política Monetaria tiene en las tasas de interés, por lo que en este trabajo se pretende proponer el modelo adecuado a dicho fin.

Preguntas de Investigación:

1. Cómo afecta la tasa de Política Monetaria a la tasa de interés del sector financiero?
 2. Qué variables influyen o afectan el cambio de la tasa de interés del sector financiero?
 3. Qué modelo explica el efecto de la tasa de Política Monetaria en la tasa de interés del sector financiero?
- Observación: Primero intentaremos ajustar un modelo ARIMA.

II. PRELIMINARES Y NOTACIÓN

Definición 1. *Tasa de Interés* Es la cantidad de dinero que por lo regular representa un porcentaje del crédito o préstamo

que se ha requerido y que el deudor deberá pagar a quien le presta.

Definición 2. *Política Monetaria:* Es la disciplina de la política económica que controla los factores monetarios para garantizar la estabilidad de precios y el crecimiento económico.

Definición 3. *La tasa de política monetaria (TPM), es la tasa de interés objetivo para las operaciones interbancarias que el banco central procura lograr mediante sus instrumentos de política monetaria: operaciones de mercado abierto, facilidades de crédito y depósito.*

Definición 4. *Tasas de Interés Activas:* Son aquellas que cobran las entidades bancarias por los créditos que otorgan

Definición 5. *Tasas de Interés Pasivas:* Son las que pagan las entidades bancarias por los depósitos que se hagan en éstas.

Definición 6. *Promedio Ponderado* Se hace de acuerdo a la participación de cada banco respecto al total de préstamos concedidos en la semana por el Sistema Bancario.

Definición 7. *Índice de Precios al Consumidor:* Es el indicador utilizado para la cuantificación de la inflación, su cálculo y divulgación lo ejecuta el Banco Central de Honduras, publicando en los primeros días de cada mes el comportamiento de los precios al consumidor del mes anterior.

Definición 8. *Prueba de Causalidad de Granger* Es un test consistente en comprobar si los resultados de una variable sirven para predecir a otra variable. Para ello se tiene que comparar y deducir si el comportamiento actual y pasado de una serie temporal A predice la conducta de una serie temporal B.

II-A. Series de tiempo

Definición 9. Es una sucesión de observaciones de una variable tomadas en varios instantes de tiempo [1]:

- Nos interesa estudiar los cambios en esa variable con respecto al tiempo.
- Predecir sus valores futuros.

Representación gráfica de una serie de tiempo: Se representa por medio de una gráfica de líneas; el eje horizontal se representan los períodos y el eje vertical se representan los valores de la serie de tiempo.

Clasificación de series temporales [3]

- Una serie es estacionaria si la media y la variabilidad se mantienen constantes a lo largo del tiempo.
- Una serie es no estacionaria si la media y/o la variabilidad cambian a lo largo del tiempo.

Componentes de la serie de tiempo: [3] El método clásico identifica cuatro componentes:

- Tendencia (T): Es el movimiento general a largo plazo de los valores de la serie de tiempo sobre un extenso periodo de años.
- Variaciones cíclicas (C): Son los movimientos ascendentes y descendentes recurrentes respecto a la tendencia con una duración de varios años.
- Variaciones estacionales (E): Son los movimientos ascendentes y descendentes respecto de la tendencia que se consuman en un año y se repiten anualmente. Se identifican en periodos trimestrales.
- Variaciones irregulares (I): Variaciones erráticas respecto de la tendencia que no pueden atribuirse a influencias cíclicas o estacionales.

Análisis de una serie de tiempo: Es el procedimiento por el cual se identifican y aíslan los factores relacionados con el tiempo que influyen en los valores observados. Una vez identificados, estos factores contribuirán en la interpretación de valores históricos y a pronosticar valores futuros. La forma mas usual de representar una serie de tiempo es en función de las componentes tendencia y estacionalidad, es decir, mediante la ecuación: [3]

$$X_t = T_t + E_t + \epsilon_t,$$

donde:

X_t = el valor de la serie temporal en el periodo t ;

T_t = componente de tendencia en el periodo t ;

E_t = es una función que representa la componente estacional;

ϵ_t = el término del error en el periodo t .

II-B. Modelo

Un modelo para una serie temporal es cualquier conjunto de hipótesis bien definidas sobre las propiedades estadísticas de dicha serie.

Definición 10. *Modelo ARIMA [2] Un proceso (X_t) es integrado de orden d ($d \geq 0$ entero) si y sólo si (X_t) sigue un modelo autorregresivo-integrado-media móvil de orden (p, d, q) o $ARIMA(p, d, q)$ (del inglés AutoRegressive-Integrated- Moving Average), donde p representa el orden del proceso autorregresivo, d el número de diferencias que son necesarias para que el proceso sea estacionario*

y q representa el orden del proceso de medias móviles del tipo:

$$\phi(B)\Delta^d X_t = \mu + \theta(B)A_t \text{ para todo } t = 0, \pm 1, \pm 2, \dots$$

donde las raíces de las ecuaciones $\phi(x) = 0$ y $\theta(x) = 0$ están fuera del círculo unitario.

Etapas en la elaboración de un modelo arima

- **Identificación:** Para identificar cuál es el proceso ARIMA que ha generado una determinada serie temporal es necesario que los datos sean estacionarios, es decir, no pueden presentar tendencia creciente o decreciente (si presentan tendencia habría que diferenciar la serie porque la serie no es estacionaria en media), ni tampoco pueden presentar fluctuaciones de diferente amplitud. Si la dispersión no se mantiene constante entonces la serie no es estacionaria en varianza y habría que transformarla siendo, la transformación logarítmica la más habitual. Una vez que la serie es estacionaria es necesario obtener las funciones de autocorrelación simple (ACF) y parcial (PACF) muestrales para determinar el proceso $ARIMA(p,d,q)$ más adecuado que haya podido generar la serie estacionaria.
- **Estimación:** Después de identificar el proceso que ha generado los datos de una determinada serie temporal es necesario estimar los parámetros de los que depende.
- **Validación:** Después de estimar el modelo es necesario comprobar si se ajusta o no de forma adecuada a los datos observados de la serie temporal objeto de estudio. Para comprobar si el modelo es adecuado se suele realizar lo siguiente: análisis de los parámetros estimados, análisis de los residuos, análisis de la bondad del ajuste y análisis de estabilidad.
- **Predicción:** Una vez estimado y validado el modelo ARIMA se puede utilizar para obtener valores futuros de la variable objeto de estudio. Las predicciones obtenidas pueden ser de dos tipos: puntuales o por intervalos. La predicción puntual se obtiene calculando el valor esperado de la variable en el período futuro $T + l$ condicionado al conjunto de información disponible hasta el período T . Y la predicción por intervalos, para un nivel de confianza del 95 por ciento, se obtiene sumando y restando a la predicción puntual la desviación típica del error de predicción multiplicada por el valor tabulado para el 95 por ciento de confianza.

Definición 11. *El Modelo Vector Autorregresivo (VAR) es un conjunto de k regresiones temporales con k variables y $p * k$ variables independientes rezagadas.*

De qué tratan los modelos VAR?

- Son modelos econométricos multivariados.
- Es una extensión de los modelos Autorregresivos Univariados.
- No hay variables endógenas o exógenas.

- Son un sistema de regresiones.
- El caso más sencillo de un VAR es el bivariado.
- Se utilizan para pronósticos similar a otros modelos econométricos.
- VAR(p), donde p es el orden del modelo.

III. RESULTADOS

III-A. Primer resultado

Como primer resultado `gas6677.dat` contiene datos mensuales del consumo de gasolina en España entre Enero de 1966 y agosto de 1977. Utilizaremos el lenguaje de programación R, el código desarrollado en este primer resultado está disponible en: <https://github.com/Eduar-Amaya/PoliticaMonetaria.git>

Haciendo un Análisis de Series Temporales vamos hacer una predicción de cómo será el consumo de gasolina en España a partir del mes de Septiembre de 1977 a Junio de 1978.

Vamos a ajustar un modelo ARIMA, sin embargo muchos modelos de series temporales (ARIMA) se exige que las series sean estacionarias, es decir, sin componente de tendencia ni estacionalidad además que la variabilidad sea constante. En la figura 1 se aprecia que la serie presenta una tendencia ascendente (la serie no es estacionaria en media), con esto se puede afirmar que la serie no es estacionaria. También se puede apreciar que la serie no es estacionaria en cuanto a la varianza, ya que que hay variabilidad.




Figura 1. Gráfica de la Serie.

Primero necesitamos controlar la variabilidad (que sea constante) para ello aplicamos logaritmo como se observa en la figura 2, la variabilidad parece ser constante.




Figura 2. Variabilidad Estable.

Luego que la variabilidad es constante se procede a eliminar la tendencia y la estacionalidad, para ello se recomienda

utilizar diferencias o logaritmos en este caso vamos a utilizar diferencias. En R las funciones `ndiffs` y `nsdiffs` nos dan el número de diferencias regulares y estacionales respectivamente que se necesita llevar a cabo para que la serie sea estacionaria. En R se hace de la siguiente manera:

```
> ndiffs(gas.ts)
[1] 1
> nsdiffs(gas.ts)
[1] 1
```

Significa que necesitamos diferenciar una vez para eliminar la tendencia y una vez para eliminar la estacionalidad. En la figura 3 se observa que no hay tendencia y en la figura 4 se muestra como la serie parece ser estacionaria luego que se haya eliminado la componente estacional.




Figura 3. Serie Diferenciada una vez.




Figura 4. Serie Diferenciada dos veces.

Para comprobar que la serie es estacionaria utilizaremos el Test de Dickey-Fuller con $\alpha = 0,05$

- H_0 : La serie no es estacionaria. Si $p > 0,05$
- H_1 : La serie es estacionaria. Si $p < 0,05$

A continuación se muestra como se hace en R:

```
> adf <- adf.test(dif2_gas.ts)
> adf$p.value
[1] 0.01
```

El valor $p = 0,01$ del test nos indica que se puede rechazar la hipótesis nula H_0 , es decir, se acepta la hipótesis alternativa H_1 . Por lo tanto la serie es estacionaria.

Las figuras 5 y 6 nos indican el número de medias móviles y autoregresivos respectivamente para determinar el proceso

ARIMA(p,d,q) más adecuado que haya podido generar la serie estacionaria.

Modelos	df	BIC
arima1	7	1078.424
arima2	9	1080.073
arima3	7	1066.711
arima4	9	1072.139

Cuadro II
CRITERIO BIC




Figura 5. Determina el numero de medias móviles




Figura 6. Determina el numero de Autoregresivos

Identificación del Modelo

Observando las figuras 5 y 6 podemos plantear varios modelos para el análisis de la serie como ser: $ARIMA(2, 0, 2)(0, 1, 2)$, $ARIMA(2, 0, 2)(2, 1, 2)$, $ARIMA(2, 1, 2)(0, 1, 2)$, incluso $ARIMA(2, 1, 2)(2, 1, 2)$, etc.

En las tablas I y II se puede apreciar que los ajustes que mejor AIC (Criterio de Información Akaike) y BIC (Criterio de Información Bayesiano) tienen dos autoregresivos, una diferencia y dos medias móviles; en la parte estacional cero autoregresivos, una diferencia y dos medias móviles. Siendo $ARIMA(2,1,2)(0,1,2)$ el modelo que los tests arrojan con menor valor y por tanto con mayor consideración. Una vez estimados los modelos y elegido el mejor de ellos, procedemos a la validación del modelo.

Modelos	df	AIC
arima1	7	1058.460
arima2	9	1054.405
arima3	7	1046.801
arima4	9	1046.542

Cuadro I
CRITERIO AIC

Validación

En las figuras 7 y 8 podemos apreciar que no hay ningún rezago significativo (aparte del 0 que por definición es 1) que denote ningún tipo de estructura. Por tanto podemos decir que los residuos son ruido Blanco.




Figura 7. Función de Autocorrelación




Figura 8. Función de Autocorrelación Parcial

Para saber si nuestro modelo se ajusta bien los residuos deben ser Ruido Blanco. Para comprobar que los residuos son ruido blanco vamos a utilizar el Test de Ljung-Box para Ruido Blanco con $\alpha = 0,05$:

- H_0 : Ruido blanco si $p > 0,05$
- H_1 : No hay ruido blanco si $p < 0,05$

A continuación se muestra cómo se hace en R

```
> lb <- Box.test(arima3$residuals,
  type = "Ljung-Box")
> lb$p.value
[1] 0.9169298
```

El valor $p = 0,9169298$ del test nos indica que se acepta la hipótesis nula H_0 , es decir, que hay ruido blanco. Por tanto el modelo se ajusta bien, que el modelo se ajusta significa que tiene media igual a cero, varianza constante y que los errores están serialmente correlacionados.

Vamos a corroborar graficando el error cómo se muestra en la figura 9 que el error tiene media igual a cero. Por tanto validamos nuestro modelo, implica que podemos hacer las predicciones.




Figura 9. Gráfica del Error

Predicción:

Queremos saber cómo será el consumo de gasolina en España en los 10 meses siguientes. En la tabla III se observa los valores y en la figura 10 se observa su comportamiento.

Meses	Point Forecast	Lo 95	Hi 95
Sep 1977	451.3333	423.6668	478.9999
Oct 1977	420.3339	392.0648	448.6029
Nov 1977	389.7801	357.9256	421.6346
Dec 1977	426.9398	394.5935	459.2861
Jan 1978	396.3406	362.7959	429.8853
Feb 1978	374.9805	341.0508	408.9103
Mar 1978	419.6776	385.1743	454.1810
Apr 1978	442.3261	407.5086	477.1436
May 1978	433.6475	398.4635	468.8316
Jun 1978	456.6717	421.2155	492.1278

Cuadro III
PREDICCIONES




Figura 10. Gráfica de las Predicciones

Para el mes de Septiembre de 1977 el consumo será de 451.333, con un intervalo de confianza de 95 por ciento el consumo estará entre 423,6668 – 478,9999 y así sucesivamente para los otros meses. Recordemos que estos datos son de Enero de 1966 y agosto de 1977, si estos datos fueran mas actuales los resultados serían diferentes, esto por el crecimiento poblacional o por el precio de la gasolina.

III-B. Segundo Resultado

Para este segundo resultado se ha considerado la base de datos *DatosBCH.csv* contiene datos mensuales de

la Tasa de Política Monetaria (TPM) e Índice de Precios al Consumidor (IPC) que comprenden del Mes de Mayo de 2005 a Diciembre de 2012 que fueron extraídos de <http://www.secmca.org/tempus23/datos.jsp>, además contiene datos de las Tasas de Interés Activas (TIA) y Tasas de Interés Pasivas (TIP) de los Bancos Comerciales correspondientes al periodo antes descrito que fueron extraídos de <https://www.bch.hn/estadisticas-y-publicaciones-economicas/sector-monetario/tasas-de-interes>.

Se ha utilizado el lenguaje de programación R, el código correspondiente a este reporte está disponible en <https://github.com/Eduar-Amaya/PoliticaMonetaria.git>:

Entre las limitaciones para este reporte que suelen presentar los datos de acuerdo a la fuente que fueron encontrados se tiene que los datos correspondientes a las Tasas de Interés (Activas y Pasivas) de los Bancos Comerciales reflejan resultados promedios ponderados y por tanto no capturan la heterogeneidad entre los diferentes actores del sistema. El resultado de este escenario es la probable manifestación de respuestas diferentes de los Bancos ante impulsos de la Tasa de Política Monetaria e Índice de Precios al Consumidor.

Primero comenzamos graficando las series. En la figura 11 se puede observar que las series a través del tiempo no tienen un comportamiento estacionario, lo cual se corroboró con el test de Dickey-Fuller dando los siguientes resultados para TIA, TIP, TPM y IPC respectivamente con las siguientes hipótesis:

- H_0 : La serie no es estacionaria. Si $p > 0,05$
- H_1 : La serie es estacionaria. Si $p < 0,05$

```
> adf <- adf.test(TIA.ts)
> adf$p.value
[1] 0.4685365
```

```
> TPdf <- adf.test(TIP.ts)
> TPdf$p.value
[1] 0.5209106
```

```
> Tdf <- adf.test(TPM.ts)
> Tdf$p.value
[1] 0.3135323
```

```
> Idf <- adf.test(IPC.ts)
> Idf$p.value
[1] 0.4156172
```




Figura 11. Representacion de las Series




Figura 12. Series Estacionarias

Identificación del Modelo

La estacionariedad de un VAR requiere una condición de estabilidad que ponemos a prueba solo después de identificar el VAR. Así como en los modelos ARIMA para que una serie sea estacionaria es necesario diferenciar la serie en este caso fué necesario llevar a cabo dos diferencias.

En la figura 12 se puede observar cómo las series parecen ser estacionarias después de haber aplicado logaritmos y diferenciado una vez. Lo dicho anteriormente lo comprobamos aplicando el Test de Dickey-Fuller dando los siguientes resultados para TIA, TIP, TPM y IPC respectivamente con las siguientes hipótesis:

- H_0 : La serie no es estacionaria. Si $p > 0,05$
- H_1 : La serie es estacionaria. Si $p < 0,05$

```
> adf2 <- adf.test(dif2)
[1] 0.01
```

```
> TIPdf2$p.value
[1] 0.01
```

```
> Tdf2 <- adf.test(Tdif2)
[1] 0.01
```

```
> Idf2 <- adf.test(Idif2)
[1] 0.01
```

El $p = 0,01$ observado nos asegura que debemos rechazar H_0 y aceptar H_1 , por tanto las series son estacionarias.

```
> VARselect(VarDatos, type = "const")
$selection
AIC (n)   HQ (n)   SC (n)  FPE (n)
      2      2      1      2
$criteria
              1              2
AIC (n) -2.897336e+01 -2.940934e+01
HQ (n)  -2.873461e+01 -2.897958e+01
SC (n)  -2.837786e+01 -2.833742e+01
FPE (n)  2.614035e-13  1.695701e-13

              3              4
AIC (n) -2.938401e+01 -2.919768e+01
HQ (n)  -2.876325e+01 -2.838591e+01
SC (n)  -2.783570e+01 -2.717296e+01
FPE (n)  1.752810e-13  2.143046e-13

              5              6
AIC (n) -2.911529e+01 -2.901341e+01
HQ (n)  -2.811252e+01 -2.781963e+01
SC (n)  -2.661416e+01 -2.603588e+01
FPE (n)  2.383683e-13  2.736561e-13

              7              8
AIC (n) -2.922139e+01 -2.908327e+01
HQ (n)  -2.783661e+01 -2.750749e+01
SC (n)  -2.576746e+01 -2.515293e+01
FPE (n)  2.340351e-13  2.884333e-13

              9             10
AIC (n) -2.897523e+01 -2.924596e+01
HQ (n)  -2.720843e+01 -2.728817e+01
SC (n)  -2.456848e+01 -2.436281e+01
FPE (n)  3.533455e-13  3.054326e-13
```

Para cada longitud de rezago, la tabla reporta (de arriba hacia abajo), el Criterio de información de Akaike (AIC), Criterio de información de Hannan y Quinn (HQ), el criterio información bayesiana de Schwarz (SC) y el error de predic-

ción final de Akaike (FPE). Los cuatro criterios de información se basan en la teoría de la información y se supone que indican la información relativa perdida cuando los datos se ajustan usando diferentes especificaciones. La longitud de rezago que produce el valor mínimo del estadístico de la información es la especificación elegida. En este caso, tres criterios eligen 2 rezagos, por tanto elegimos 2 rezagos para nuestro modelo.

Así que seleccionamos nuestro modelo $VAR(2)$ con dos rezagos. El modelo estimado para las ecuaciones de TPM, TIP, TIA e IPC se tiene:

Estimation results for equation VTdif2:

```
=====
VTdif2 = VTdif2.11 + VTIPdif2.11 +
Vdif2.11 + VIdif2.11 + VTdif2.12 +
VTIPdif2.12 + Vdif2.12 +
VIdif2.12 + const

              Estimate    t value    Pr(>|t|)
VTdif2.11    -0.7154553   -6.755   2.18e-09
VTIPdif2.11    0.4897181    3.088   0.00278
Vdif2.11     -0.2932086   -2.093   0.03952
VIdif2.11      4.4745962    3.002   0.00359
VTdif2.12    -0.3201612   -3.100   0.00268
VTIPdif2.12    0.3102220    1.902   0.06087
Vdif2.12     -0.1427413   -1.003   0.31906
VIdif2.12      0.8749087    0.587   0.55884
const        -0.0002324   -0.039   0.96903
```

Estimation results for equation VTIPdif2:

```
=====
VTIPdif2 = VTdif2.11 + VTIPdif2.11 +
Vdif2.11 + VIdif2.11 + VTdif2.12 +
VTIPdif2.12 + Vdif2.12 +
VIdif2.12 + const

              Estimate    t value    Pr(>|t|)
VTdif2.11     2.529e-01    3.386   0.00111
VTIPdif2.11  -4.802e-01   -4.294   4.94e-05
Vdif2.11      2.355e-02    0.238   0.81219
VIdif2.11    -4.699e-01   -0.447   0.65613
VTdif2.12     1.595e-01    2.190   0.03145
VTIPdif2.12  -6.779e-02   -0.589   0.55736
Vdif2.12      6.698e-02    0.667   0.50656
VIdif2.12    -1.745e+00   -1.661   0.10074
const         7.879e-05    0.019   0.98511
---
```

Estimation results for equation Vdif2:

```
=====
Vdif2 = VTdif2.11 + VTIPdif2.11 +
Vdif2.11 + VIdif2.11 + VTdif2.12 +
VTIPdif2.12 + Vdif2.12 +
VIdif2.12 + const

              Estimate    t value    Pr(>|t|)
VTdif2.11     0.1434632    1.916   0.0589
VTIPdif2.11    0.1290316    1.151   0.2532
Vdif2.11     -0.9612169   -9.709   4.04e-15
```

```
VIdif2.11      0.2351107    0.223   0.8240
VTdif2.12      0.0852266    1.167   0.2465
VTIPdif2.12   -0.0267962   -0.232   0.8168
Vdif2.12     -0.5365273   -5.332   8.98e-07
VIdif2.12    -0.9097280   -0.864   0.3904
const         0.0007747    0.184   0.8547
```

Estimation results for equation VIdif2:

```
=====
VIdif2 = VTdif2.11 + VTIPdif2.11 +
Vdif2.11 + VIdif2.11 + VTdif2.12 +
VTIPdif2.12 + Vdif2.12
+ VIdif2.12 + const
```

```
              Estimate    t value    Pr(>|t|)
VTdif2.11    -3.519e-03   -0.459   0.64716
VTIPdif2.11  -1.935e-02   -1.687   0.09554
Vdif2.11     -1.486e-02   -1.467   0.14629
VIdif2.11    -3.658e-01   -3.393   0.00108
VTdif2.12    -5.297e-04   -0.071   0.94365
VTIPdif2.12   1.563e-02    1.325   0.18906
Vdif2.12     -1.071e-02   -1.040   0.30142
VIdif2.12    -2.172e-01   -2.015   0.04731
const        -8.339e-05   -0.193   0.84728
```

Una vez que hemos identificado nuestro modelo procedemos aplicar las Pruebas de Especificación

- **Condición de Estabilidad:** Si las raíces de los polinomios son menores a 1 se satisface la condición de estabilidad, como las raíces de los polinomios característicos son menores como se observa a continuación. Por tanto nuestro modelo es estable:

```
> summary(Var1)
```

```
Roots of the characteristic polynomial:
0.7438 0.7438 0.6982 0.6982 0.5659
0.5659 0.03506 0.03506
```

- **Prueba de Autocorrelación Serial en los Residuales:**

1 H_0 : Los Residuales no están correlacionados, $p > 0,05$

2 H_1 : Los Residuales están correlacionados, $p < 0,05$

El p valor observado fué $p - value < 2,2e - 16$. Por lo tanto los Residuales sí están correlacionados

- **Prueba de Normalidad de los Residuales:**

1 H_0 : Los Residuales se distribuyen Normal sí, $p > 0,05$

2 H_1 : Los Residuales no se distribuyen Normal sí, $p < 0,05$

Observando el p de Kurtosis y el Sesgo da el valor de $p - value = 0,002144$ y $p - value = 0,01808$ respectivamente. Por lo tanto los residuales no se distribuyen Normal.

- **Prueba de Homocedasticidad de la Varianza de los Residuales:**

1 H_0 : La Varianza de los residuales es constante, si $p > 0,05$

2 H_1 : La Varianza de los residuales no es constante, si $p < 0,05$

El $p - value = 1$ significa que la varianza de los residuales es constante.

Prueba de Causalidad de Granger

Según las pruebas de causalidad de Granger los resultados muestran que:

- La TPM sí causa en el sentido de Granger a la TIP.
- La TIP sí causa en el sentido de Granger a la TIA.
- La TIP sí causa en el sentido de Granger al IPC.
- La IPC sí causa en el sentido de Granger a la TIA.
- La IPC sí causa en el sentido de Granger a la TIP.
- La IPC sí causa en el sentido de Granger a la TPM.

Función de Impulso-Respuesta

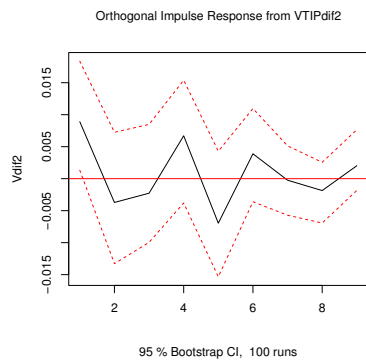


Figura 13. Cómo Responde la TIA Ante un Impulso de la TIP.




Figura 14. Cómo Responde la TIA Ante un Impulso del IPC.




Figura 15. Cómo Responde la TIP Ante un Impulso de la TPM.




Figura 16. Cómo Responde la TIP Ante un Impulso del IPC.

La figura 13 muestra los impulsos de la Tasa de Interés Pasiva (TIP), la figura 14 y 15 muestra los impulsos del Índice de Precios al Consumidor (IPC), y la figura 16 muestra los impulsos de la Tasa de Política Monetaria.

El impacto de un crecimiento mensual de la TIP $VTIPdif2$ induce a un aumento en la TIA $Vdif2$ por un corto período de tiempo, inversamente el decrecimiento de la TIP $VTIPdif2$ induce a una rebaja en la TIA $Vdif2$. Un crecimiento mensual del IPC $VIdif2$ la tasa TIA tiende a aumentar. Un rebaja en la TPM $VTdif2$ produce una rebaja en las TIP $VTIPdif2$.

III-C. Tercer Resultado

Para este tercer resultado se ha considerado la base de datos *Datos2BCH.csv* que contiene datos mensuales de la Tasa de Política Monetaria (TPM), Índice de Precios al Consumidor (IPC) que comprenden del Mes de Enero de 2013 a Septiembre de 2021 que fueron extraídos de <http://www.secmca.org/tempus23/datos.jsp>, además contiene datos de las Tasas de Interés Activas (TIA) y Tasas de Interés Pasivas (TIP) de los Bancos Comerciales correspondientes al período antes descrito los cuáles fueron extraídos de <https://www.bch.hn/estadisticas-y-publicaciones-economicas/sector-monetario/tasas-de-interes>.

Lo que haremos será determinar el efecto de la TPM en las tasas de interés de los Bancos Comerciales de Honduras utilizando las variables antes descritas haciendo uso de modelos

VAR.

La figura 17 nos permite observar la representación de las series temporales correspondientes a TPM, TIA, TIP e IPC las cuales a través del tiempo no parecen ser estacionarias. Haciendo uso del Test de Dickey-Fuller comprobamos que en efecto las series no son estacionarias:

- H_0 : La serie no es estacionaria. Si $p > 0,05$
- H_1 : La serie es estacionaria. Si $p < 0,05$

```
> adf <- adf.test(TIA.ts)
> adf$p.value
[1] 0.2663158
```

```
> TPdf <- adf.test(TIP.ts)
> TPdf$p.value
[1] 0.827974
```

```
> Tdf <- adf.test(TPM.ts)
> Tdf$p.value
[1] 0.7817857
```

```
> Idf <- adf.test(IPC.ts)
> Idf$p.value
[1] 0.7472833
```




Figura 17. Representación de las Series

Aplicando logaritmos además de diferenciar las series una vez se determina que las series TIA.ts, TIP.ts y IPC.ts al aplicar el Test de Dickey-Fuller son series estacionarias, pero en los modelos VAR las series deben ser del mismo orden así que fué necesario aplicar una diferencia más a cada serie. Como se puede observar en la figura 18 que las series son estacionarias, lo que se comprueba aplicando el Test de Dickey-Fuller que efecto lo son:

- H_0 : La serie no es estacionaria. Si $p > 0,05$
- H_1 : La serie es estacionaria. Si $p < 0,05$

```
> adf2 <- adf.test(dif2)
[1] 0.01
```

```
> TIPdf2$p.value
[1] 0.01
```

```
> Tdf2 <- adf.test(Tdif2)
[1] 0.01
```

```
> Idf2 <- adf.test(Idif2)
[1] 0.01
```

El $p = 0,01$ observado nos asegura que debemos rechazar H_0 y aceptar H_1 , por tanto las series son estacionarias.

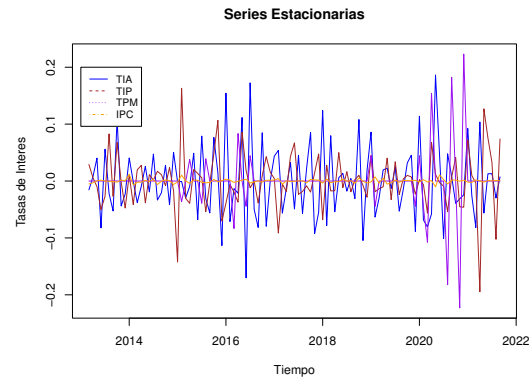


Figura 18. Series Estacionarias

Identificación del Modelo Para evitar errores a la hora de elegir los retardos, usaremos criterios de selección que consisten en la elección del número de retardos óptimo que minimiza el valor de los criterios de información AIC y HQ. Estos métodos están basados en la comparación de la matriz de varianzas y covarianzas del modelo para diferentes retardos, penalizando los modelos que tienen más variables explicativas. Los criterios son los siguientes:

$$AIC(p) = \log |\Omega_p| + \frac{2}{N}pM^2 \quad (1)$$

$$SC(p) = \log |\Omega_p| + \frac{2\log(\log(N))}{N}pM^2 \quad (2)$$

$$HQ(p) = \log |\Omega_p| + \frac{\log(N)}{N}pM^2 \quad (3)$$

dónde N corresponde al número de observaciones, Ω_p a la matriz de varianzas y covarianzas del modelo estimado con un número p de retardos y M al número de variables dependientes del modelo. El segundo término de cada uno de los criterios corresponde a la penalización antes mencionada. AIC tiende a sobreestimar p , HQ y SC son criterios consistentes, HQ y SC funcionan mejor en muestras grandes, siendo no tan claro en muestras pequeñas. El último criterio que usaremos para optimizar el número de retardos está basado en el Error de Predicción Final (FPE). El orden del modelo autorregresivo será aquel que minimiza el error cuadrático medio. Entonces, un modelo óptimo es el que minimiza la siguiente ecuación:

$$FPE(p) = |\Omega_p| \left[\frac{N + pM + 1}{N - pM - 1} \right]^M \quad (4)$$

Este criterio funciona peor que HQ y SC en muestras grandes mientras que para muestras pequeñas no está claro cuál funciona mejor.

Observando los datos que se presentan a continuación, notamos que no hay armonía entre los diferentes criterios acerca de cuál es el número de retardos óptimo. Podemos apreciar que no hay una única solución en la elección del número de retardos óptimo. Los contrastes basados en los criterios AIC y FPE señalan un p óptimo de 4 retardos, mientras que los criterios HQ y SC concluyen en que el número de retardos óptimo es 3 y 2 respectivamente. Dada la concordancia de los dos primeros criterios (AIC y FPE) imponemos un número óptimo de retardos de $p = 4$ para nuestro modelo VAR.

```
> VARselect(VarDatos, type = "const")
$selection
```

AIC(n)	HQ(n)	SC(n)	FPE(n)
4	3	2	4

```
$criteria
```

	1	2
AIC(n)	-2.945765e+01	-3.040271e+01
HQ(n)	-2.923773e+01	-3.000687e+01
SC(n)	-2.891300e+01	-2.942235e+01
FPE(n)	1.610228e-13	6.270822e-14

	3	4
AIC(n)	-3.064543e+01	-3.069777e+01
HQ(n)	-3.007366e+01	-2.995007e+01
SC(n)	-2.922935e+01	-2.884598e+01
FPE(n)	4.943801e-14	4.735276e-14

	5	6
AIC(n)	-3.068495e+01	-3.058387e+01
HQ(n)	-2.976132e+01	-2.948431e+01
SC(n)	-2.839744e+01	-2.786065e+01
FPE(n)	4.869133e-14	5.509592e-14

	7	8
AIC(n)	-3.069010e+01	-3.050080e+01
HQ(n)	-2.941461e+01	-2.904938e+01
SC(n)	-2.753116e+01	-2.690614e+01
FPE(n)	5.114194e-14	6.452294e-14

	9	10
AIC(n)	-3.055013e+01	-3.046685e+01
HQ(n)	-2.892278e+01	-2.866357e+01
SC(n)	-2.651975e+01	-2.600076e+01
FPE(n)	6.501281e-14	7.605280e-14

Luego de identificar nuestro modelo aplicamos las pruebas de especificación:

- **Condición de Estabilidad:** Si las raíces de los polinomios son menores a 1 se satisface la condición de estabilidad, como las raíces de los polinomios característicos son menores que 1 como se observa a continuación. Por tanto nuestro modelo es estable:

```
> summary(Var2)
```

```
Roots of the characteristic polynomial:
0.8815 0.8815 0.8045 0.8045 0.762 0.762
0.7611 0.734 0.734 0.6435 0.6435 0.6416
```

```
0.6416 0.5273 0.5273 0.09228
```

■ Prueba de Autocorrelación Serial en los Residuales:

- 1 H_0 : Los Residuales no están correlacionados, $p > 0,05$
- 2 H_1 : Los Residuales están correlacionados, $p < 0,05$

El p valor observado fué $p - value < 2,2e - 16$. Por lo tanto los Residuales sí están correlacionados.

■ Prueba de Normalidad de los Residuales:

- 1 H_0 : Los Residuales se distribuyen Normal sí, $p > 0,05$
- 2 H_1 : Los Residuales no se distribuyen Normal sí, $p < 0,05$

Observando el p de Kurtosis y el Sesgo da el valor de $p - value < 2,2e - 16$ y $p - value = 0,008641$ respectivamente. Por lo tanto los residuales no se distribuyen Normal.

■ Prueba de Homocedasticidad de la Varianza de los Residuales:

- 1 H_0 : La Varianza de los residuales es constante, si $p > 0,05$
- 2 H_1 : La Varianza de los residuales no es constante, si $p < 0,05$

El $p - value = 1$ significa que la varianza de los residuales es constante.

Prueba de Causalidad de Granger

Según las pruebas de causalidad de Granger los resultados muestran que:

- La TPM sí causa en el sentido de Granger a la TIP.
- La TPM sí causa en el sentido de Granger a la TIA.
- La TIA sí causa en el sentido de Granger a la TPM.
- La TIA sí causa en el sentido de Granger a la TIP.
- La TIA sí causa en el sentido de Granger al IPC.
- La IPC sí causa en el sentido de Granger a la TIP.
- La IPC sí causa en el sentido de Granger a la TPM.

Funciones Impulso-Respuesta

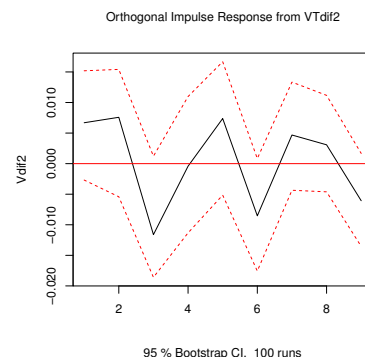


Figura 19. Cómo Responde la TIA Ante un Impulso de la TPM.

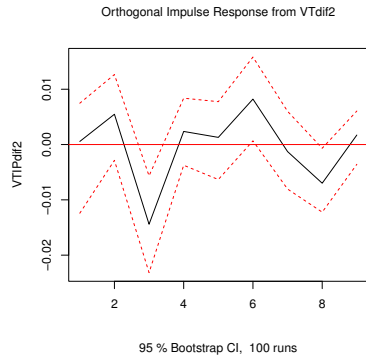


Figura 20. Cómo Responde la TIP Ante un Impulso de la TPM.

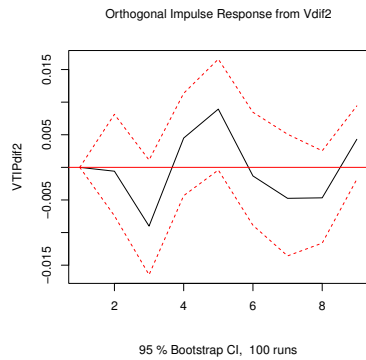


Figura 21. Cómo Responde la TIP Ante un Impulso de la TIA.




Figura 22. Cómo Responde la TIP Ante un Impulso del IPC.

La figura 19 nos muestra que ante un impulso de la Tasa de Política Monetaria la Tasa de Interés Activa en el primer mes tendría un pequeño incremento que decrece en el tercer mes para luego tener un nuevo incremento hasta el quinto mes, de manera similar ocurre en la Tasa de Interés Pasiva ante un impulso de la Tasa de Política Monetaria como se aprecia en la figura 20. En las figuras 21, 22 observamos cómo respondería las Tasas de Interés Pasivas y Activas respectivamente ante impulsos del Índice de Precios al Consumidor que en el primer

mes tendría un comportamiento estable, que luego tendría un decrecimiento en el tercer mes para luego tener un incremento hasta el quinto mes. En las gráficas anteriores notamos que el punto más alto se alcanza en el quinto mes y el más bajo en el tercer mes.

III-D. Cuarto Resultado

Para este resultado se ha considerado la base de datos *BancoCh.csv* la cuál contiene datos mensuales de; Tasas de Interés (Activas y Pasivas), Índice de Precios al Consumidor, Tasa de Política Monetaria y Tasa de Cambio del mes de Mayo de 2005 a Agosto de 2021 que fueron extraídos de <http://www.secmca.org/tempus23/datos.jsp>. Para este reporte consideraremos primero del mes de Mayo de 2005 a Diciembre de 2012.

Lo que haremos será determinar el Efecto de la Tasa de Política Monetaria en las Tasa de Interés del Sistema Financiero utilizando modelo de Vectores Autorregresivos (VAR).

En la figura 23 se puede observar que las series a través del tiempo no parecen ser estacionarias. Y el cuadro IV nos permite determinar que en efecto las series no son estacionarias




Figura 23. Representación de las Series

Análisis de Estacionariedad. Datos Mensuales			
Serie o Variables	Estadístico ADF	Prob.	Estacionaria
TIA	-2.677297	0.2970746	No
TIP	-1.82358	0.6489775	No
TPM	-2.637371	0.3135323	No
IPC	-2.389713	0.4156172	No

Cuadro IV
TEST DE DICKEY-FULLER

Para poder convertir las series consideradas en estacionarias fué necesario aplicar dos diferencias, como se puede observar en la figura 24. En el cuadro V podemos observar que las series son estacionarias, dónde el término "Prob" hace referencia al p-valor.




Figura 24. Representación de las Series con dos Diferencias

Análisis de Estacionariedad. Datos Mensuales			
Serie o Variables	Estadístico ADF	Prob.	Estacionaria
TIA	-5.382785	0.01	Sí
TIP	-5.564742	0.01	Sí
TPM	-5.998554	0.01	Sí
IPC	-6.375217	0.01	Sí

Cuadro V
TEST DE DICKEY-FULLER

Análisis de los Criterios de Información		
Retardos	AIC	HQ
1	-3.391758e+01	-3.367882e+01
2	-3.414190e+01	-3.371214e+01*
3	-3.415228e+01	-3.353151e+01
4	-3.423440e+01*	-3.342264e+01
5	-3.405078e+01	-3.304801e+01
6	-3.411808e+01	-3.292431e+01
7	-3.394055e+01	-3.255576e+01
8	-3.385559e+01	-3.227980e+01
9	-3.395858e+01	-3.219179e+01
10	-3.386445e+01	-3.190665e+01

Cuadro VI
NÚMERO DE RETARDOS DEL MODELO VAR

Análisis de los Criterios de Información		
Retardos	SC	FPE
1	-3.332207e+01*	1.862371e-15
2	-3.306999e+01	1.492867e-15
3	-3.260396e+01	1.489034e-15
4	-3.220968e+01	1.391910e-15*
5	-3.154966e+01	1.713134e-15
6	-3.114055e+01	1.660636e-15
7	-3.048661e+01	2.088234e-15
8	-2.992525e+01	2.440365e-15
9	-2.955183e+01	2.420791e-15
10	-2.898129e+01	3.013935e-15

Cuadro VII
NÚMERO DE RETARDOS DEL MODELO VAR

Identificación del Modelo VAR En los cuadros VI y VII que se presentan a continuación, dónde el término "Prob" hace referencia al p-valor, notamos que no hay armonía entre los diferentes criterios acerca de cuál es el número de retardos óptimo. Podemos apreciar que no hay una única solución en la elección del número de retardos óptimo. Los contrastes basados en los criterios AIC y FPE señalan un p óptimo de $p = 4$, mientras que los criterios HQ y SC concluyen en que el número de retardos óptimo es 2 y 1 respectivamente. Dada la concordancia de los criterios (AIC y FPE) imponemos un número óptimo de retardos de $p = 4$ para nuestro modelo:

$$\begin{pmatrix} A_t \\ P_t \\ M_t \\ I_t \end{pmatrix} = \delta_{4 \times 1} + C_{4 \times 4}^i * \begin{pmatrix} A_{t-1} \\ P_{t-1} \\ M_{t-1} \\ I_{t-1} \end{pmatrix} \quad (5)$$

con $i = 1, 2, 3, 4$, dónde

$$\delta_{4 \times 1} = \begin{pmatrix} \delta_1 \\ \delta_2 \\ \delta_3 \\ \delta_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \quad (6)$$

Representación de las ecuaciones: Los parámetros estimados fueron redondeados a tres cifras decimales, por lo que el parámetro de la constante no se ha agregado ya que resulta cero al redondearlo a tres cifras decimales.

$$\begin{aligned} A_t &= \sum_{j=1}^p \beta_j A_{t-j} + \sum_{j=1}^p \gamma_j P_{t-j} + \sum_{j=1}^p \theta_j M_{t-j} + \sum_{j=1}^p \alpha_j I_{t-j} \\ P_t &= \sum_{j=1}^p \beta_j A_{t-j} + \sum_{j=1}^p \gamma_j P_{t-j} + \sum_{j=1}^p \theta_j M_{t-j} + \sum_{j=1}^p \alpha_j I_{t-j} \\ M_t &= \sum_{j=1}^p \beta_j A_{t-j} + \sum_{j=1}^p \gamma_j P_{t-j} + \sum_{j=1}^p \theta_j M_{t-j} + \sum_{j=1}^p \alpha_j I_{t-j} \\ I_t &= \sum_{j=1}^p \beta_j A_{t-j} + \sum_{j=1}^p \gamma_j P_{t-j} + \sum_{j=1}^p \theta_j M_{t-j} + \sum_{j=1}^p \alpha_j I_{t-j} \end{aligned}$$

Representación matricial:

$$\begin{pmatrix} A_t \\ P_t \\ M_t \\ I_t \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} + C_{4 \times 4}^1 \begin{pmatrix} A_{t-1} \\ P_{t-1} \\ M_{t-1} \\ I_{t-1} \end{pmatrix} + \dots + C_{4 \times 4}^4 \begin{pmatrix} A_{t-4} \\ P_{t-4} \\ M_{t-4} \\ I_{t-4} \end{pmatrix} \quad (7)$$

La estimación consistente de cada matriz es la siguiente:

$$C^1 = \begin{pmatrix} -0,787 & 0,013 & 0,034 & 0,596 \\ 0,144 & 0,153 & 0,052 & 0,086 \\ -1,009 & 1,51 & -0,908 & 5,122 \\ -0,042 & -0,035 & 0,003 & -0,46 \end{pmatrix} \quad (8)$$

$$C^2 = \begin{pmatrix} -0,501 & 0,214 & 0,048 & 0,399 \\ 0,181 & 0,326 & 0,046 & -3,355 \\ -1,073 & 1,519 & -0,632 & 3,913 \\ -0,007 & -0,018 & -0,003 & -0,349 \end{pmatrix} \quad (9)$$

$$C^3 = \begin{pmatrix} -0,302 & 0,133 & 0,019 & 0,163 \\ 0,182 & -0,183 & 0,034 & 0,011 \\ -0,048 & -0,867 & -0,319 & 4,304 \\ -0,032 & 0,021 & -0,002 & -0,14 \end{pmatrix} \quad (10)$$

$$C^4 = \begin{pmatrix} -0,112 & 0,004 & -0,003 & 0,263 \\ 0,295 & -0,313 & -0,013 & -0,278 \\ -0,707 & -1,8 & -0,169 & 0,935 \\ -0,043 & 0,055 & -0,007 & -0,113 \end{pmatrix} \quad (11)$$

Luego de identificar nuestro modelo aplicamos las pruebas de especificación:

- **Condición de Estabilidad:** Si las raíces de los polinomios son menores a 1 se satisface la condición de estabilidad, como las raíces de los polinomios característicos son menores que 1 como se observa a continuación. Por tanto nuestro modelo es estable:

```
> summary(Var3)
```

```
Roots of the characteristic polynomial:
0.8496 0.8496 0.8089 0.8089 0.7423 0.7416
0.7416 0.7262 0.7262 0.719 0.719 0.6617
0.6617 0.6534 0.6534 0.08865
```

- **Prueba de Autocorrelación Serial en los Residuales:**

1 H_0 : Los Residuales no están correlacionados, $p > 0,05$

2 H_1 : Los Residuales están correlacionados, $p < 0,05$

El p valor observado fué $p - value < 2,2e - 16$. Por lo tanto los Residuales sí están correlacionados.

- **Prueba de Normalidad de los Residuales:**

1 H_0 : Los Residuales se distribuyen Normal sí, $p > 0,05$

2 H_1 : Los Residuales no se distribuyen Normal sí, $p < 0,05$

Observando el p de Kurtosis el valor de $p - value = 0,006174$. Por lo tanto los residuales no se distribuyen Normal.

- **Prueba de Homocedasticidad de la Varianza de los Residuales:**

1 H_0 : La Varianza de los residuales es constante, si $p > 0,05$

2 H_1 : La Varianza de los residuales no es constante, si $p < 0,05$

El $p - value = 1$ significa que la varianza de los residuales es constante.

Prueba de Causalidad de Granger

Según las pruebas de causalidad de Granger los resultados muestran que:

- La TPM sí causa en el sentido de Granger a la TIP.
- La TIA sí causa en el sentido de Granger a la TPM.
- La TIA sí causa en el sentido de Granger a la TIP.

- La IPC sí causa en el sentido de Granger a la TPM.
- La TIP sí causa en el sentido de Granger a la TPM.

Funciones Impulso-Respuesta




Figura 25. Respuestas de las variables ante un Impulso de la TIA




Figura 26. Respuestas de las variables ante un Impulso de la TPM




Figura 27. Respuestas de las variables ante un Impulso del IPC

La figura 25 muestra como responden las Tasas de Interés Pasiva, Tasa de Política Monetaria ante un impulso en las Tasas de Interés Activas. Las Tasas de Interés Pasiva tienen un incremento de alrededor del 0.001 % en el segundo mes que luego tiene una estabilización en el tercer mes. En el

cuarto, quinto y sexto mes tiene un incremento del 0.001 %, 0.002 % y 0.002 % respectivamente. En el caso de la Tasa de Política Monetaria se aprecia una caída del 0.009 % y 0.024 % en el segundo y quinto mes respectivamente, mientras que para el tercer y cuarto mes tendría un incremento del 0.006 % y 0.012 % respectivamente.

La figura 26 muestra como responden las Tasas de Interés Pasiva y Activas ante un impulso en la Tasa de Política Monetaria. Las Tasas de Interés Pasiva tienen un incremento de alrededor del 0.002 % y 0.001 % en el segundo y cuarto mes respectivamente. En el quinto y séptimo mes tiene una caída del 0.001 %. En el caso de las Tasas de Interés Activa se aprecia que no hay incrementos ni caídas considerables.

La figura 27 muestra como responden las Tasas de Interés Pasiva y Activas y la Tasa de Política Monetaria ante un impulso en el Índice de Precios al Consumidor. En las Tasas de Interés Pasiva su incremento más notorio sucede en el cuarto mes y es de alrededor del 0.001 % luego tiende a estabilizarse. En las Tasas de Interés Activa su incremento más notorio sucede en el segundo mes y es de alrededor del 0.002 % luego tiende a estabilizarse. Mientras que en la Tasa de Política Monetaria en el segundo mes tiene un incremento del 0.021 % de igual manera para el cuarto y séptimo mes que es del 0.005 % y 0.006 % respectivamente, la caída más notoria se da en el tercer mes que es del 0.015 %.

DISPONIBILIDAD DE DATOS

Los datos utilizados para el primer resultado están disponibles en <https://github.com/Eduar-Amaya/PoliticaMonetaria.git>

El código fuente correspondiente a Segundo Resultado así como los datos utilizados están disponibles en <https://github.com/Eduar-Amaya/PoliticaMonetaria.git>

El código fuente correspondiente a Tercer Resultado así como los datos están disponibles en <https://github.com/Eduar-Amaya/PoliticaMonetaria.git>

El código fuente correspondiente a Cuarto Resultado así como los datos están disponibles en <https://github.com/Eduar-Amaya/PoliticaMonetaria.git>

REFERENCIAS

- [1] Peña, D. (2005)). *Análisis de series temporales*. Alianza Editorial.
- [2] José Alberto Mauricio, *Introducción al Análisis de Series Temporales*, Universidad Complutense de Madrid.
- [3] Brockwell, P.J. Y Davis, R.A (2002)., *Introduction to Time Series and Forecasting 2^a edition*, Springer.
- [4] James H. Stock, Mark W. Watson, *Introducción a la Econometría*.
- [5] Theil, H., *Principles of Econometrics*, John Wiley and Sons, Inc., New York, 1971
- [6] <https://github.com/Eduar-Amaya/PoliticaMonetaria.git>