

Efecto de la Tasa de Política Monetaria en las Tasas de Interés del Sector Financiero

Eduar Amaya
Universidad Nacional Autónoma de Honduras
e-mail: eduaramaya@unah.hn

ÍNDICE

I.	Defnición del Problema	1
II.	Preliminares y Notación	1
II-A.	Series de tiempo	1
II-B.	Modelo	2
III.	Resultados	2
III-A.	Primer resultado	2
	Referencias	5

ÍNDICE DE FIGURAS

1.	Gráfica de la Serie.	3
2.	Variabilidad Estable.	3
3.	Serie Diferenciada una vez.	3
4.	Serie Diferenciada dos veces.	3
5.	Determina el numero de medias móviles	3
6.	Determina el numero de Autore-regresivos	3
7.	Función de Autocorrelación	4
8.	Función de Autocorrelación Parcial	4
9.	Diagnóstico	4
10.	Gráfica del Error	5
11.	Gráfica de las Predicciones	5

ÍNDICE DE CUADROS

I.	Criterio AIC	4
II.	Criterio BIC	4
III.	Predicciones	5

Efecto de la Tasa de Política Monetaria en las Tasas de Interés del Sector Financiero

Resumen—El resumen no solo hace referencia al trabajo reportado, también sintetiza el trabajo documentado en aproximadamente 200 palabras. Establece el propósito, reporta la información obtenida, provee conclusiones, y recomendaciones. En esencia, resume los puntos principales del estudio de forma adecuada y precisa. Es importante referirse a los resultados principales obtenidos en tiempo pasado al describir el trabajo realizado.

En la introducción se describe de forma concisa pero con un poco más de detalle el trabajo realizado.

En uno de los párrafos de esta sección se hace especial énfasis en la contribución realizada como parte del trabajo reportado, considerando como punto de partida el problema central que motivó el proyecto de investigación y las soluciones obtenidas por el autor del documento como resultado del trabajo de investigación realizado.

Se presentan además descripciones breves del resto de las secciones del documento.

I. DEFINICIÓN DEL PROBLEMA

El objetivo primario de la Política Monetaria es alcanzar y mantener una Tasa de Inflación baja y estable, y lograr un crecimiento económico alrededor de su tendencia de largo plazo.

Esta es la única manera de lograr un crecimiento sostenido que genere empleo y mejore el nivel de vida de la población. Por el contrario, si la economía crece a un ritmo que no es sostenible, tarde o temprano se generará una crisis con consecuencias graves para la economía, deterioro de los indicadores sociales, pérdida de confianza de la población y caídas en la inversión y en el empleo.

En nuestro país no se cuenta con un modelo que ayude a medir el efecto que la tasa de Política Monetaria tiene en las tasas de interés, por lo que en este trabajo se pretende proponer el modelo adecuado a dicho fin.

Preguntas de Investigación:

1. Cómo afecta la tasa de Política Monetaria a la tasa de interés del sector financiero?
 2. Qué variables influyen o afectan el cambio de la tasa de interés del sector financiero?
 3. Qué modelo explica el efecto de la tasa de Política Monetaria en la tasa de interés del sector financiero?
- Observación: Primero intentaremos ajustar un modelo ARIMA.

II. PRELIMINARES Y NOTACIÓN

Definición 1. *Tasa de Interés* Es la cantidad de dinero que por lo regular representa un porcentaje del crédito o préstamo

que se ha requerido y que el deudor deberá pagar a quien le presta.

Definición 2. *Política Monetaria:* Es la disciplina de la política económica que controla los factores monetarios para garantizar la estabilidad de precios y el crecimiento económico.

Definición 3. *La tasa de política monetaria (TPM), es la tasa de interés objetivo para las operaciones interbancarias que el banco central procura lograr mediante sus instrumentos de política monetaria: operaciones de mercado abierto, facilidades de crédito y depósito.*

II-A. Series de tiempo

Definición 4. *Es una sucesión de observaciones de una variable tomadas en varios instantes de tiempo [1]:*

- Nos interesa estudiar los cambios en esa variable con respecto al tiempo.
- Predecir sus valores futuros.

Representación gráfica de una serie de tiempo: Se representa por medio de una gráfica de líneas; el eje horizontal se representan los períodos y el eje vertical se representan los valores de la serie de tiempo.

Clasificación de series temporales [3]

- Una serie es estacionaria si la media y la variabilidad se mantienen constantes a lo largo del tiempo.
- Una serie es no estacionaria si la media y/o la variabilidad cambian a lo largo del tiempo.

Componentes de la serie de tiempo: [3] El método clásico identifica cuatro componentes:

- Tendencia (T): Es el movimiento general a largo plazo de los valores de la serie de tiempo sobre un extenso periodo de años.
- Variaciones cíclicas (C): Son los movimientos ascendentes y descendentes recurrentes respecto a la tendencia con una duración de varios años.
- Variaciones estacionales (E): Son los movimientos ascendentes y descendentes respecto de la tendencia

que se consuman en un año y se repiten anualmente. Se identifican en periodos trimestrales.

- Variaciones irregulares (I): Variaciones erráticas respecto de la tendencia que no pueden atribuirse a influencias cíclicas o estacionales.

Análisis de una serie de tiempo: Es el procedimiento por el cual se identifican y aíslan los factores relacionados con el tiempo que influyen en los valores observados. Una vez identificados, estos factores contribuirán en la interpretación de valores históricos y a pronosticar valores futuros.

La forma mas usual de representar una serie de tiempo es en función de las componentes tendencia y estacionalidad, es decir, mediante la ecuación: [3]

$$X_t = T_t + E_t + \epsilon_t,$$

donde:

X_t = el valor de la serie temporal en el periodo t ;

T_t = componente de tendencia en el periodo t ;

E_t = es una función que representa la componente estacional;

ϵ_t = el término del error en el periodo t .

II-B. Modelo

Un modelo para una serie temporal es cualquier conjunto de hipótesis bien definidas sobre las propiedades estadísticas de dicha serie.

Definición 5. Modelo ARIMA [2] *Un proceso (X_t) es integrado de orden d ($d \geq 0$ entero) si y sólo si (X_t) sigue un modelo autorregresivo-integrado-media móvil de orden (p, d, q) o $ARIMA(p, d, q)$ (del inglés AutoRegressive-Integrated- Moving Average), donde p representa el orden del proceso autorregresivo, d el número de diferencias que son necesarias para que el proceso sea estacionario y q representa el orden del proceso de medias móviles del tipo:*

$$\phi(B)\Delta^d X_t = \mu + \theta(B)A_t \text{ para todo } t = 0, \pm 1, \pm 2, \dots$$

donde las raíces de las ecuaciones $\phi(x) = 0$ y $\theta(x) = 0$ están fuera del círculo unitario.

Etapas en la elaboración de un modelo arima

- Identificación: Para identificar cuál es el proceso ARIMA que ha generado una determinada serie temporal es necesario que los datos sean estacionarios, es decir, no pueden presentar tendencia creciente o decreciente (si presentan tendencia habría que diferenciar la serie porque la serie no es estacionaria en media), ni tampoco pueden presentar fluctuaciones de diferente amplitud. Si la dispersión no se mantiene constante entonces la serie no es estacionaria en varianza y habría que transformarla siendo, la transformación logarítmica la más habitual. Una vez que la serie es estacionaria es necesario obtener las funciones de autocorrelación simple (ACF) y parcial (PACF) muestrales para determinar el proceso

ARIMA(p,d,q) más adecuado que haya podido generar la serie estacionaria.

- Estimación: Después de identificar el proceso que ha generado los datos de una determinada serie temporal es necesario estimar los parámetros de los que depende.
- Validación: Después de estimar el modelo es necesario comprobar si se ajusta o no de forma adecuada a los datos observados de la serie temporal objeto de estudio. Para comprobar si el modelo es adecuado se suele realizar lo siguiente: análisis de los parámetros estimados, análisis de los residuos, análisis de la bondad del ajuste y análisis de estabilidad.
- Predicción: Una vez estimado y validado el modelo ARIMA se puede utilizar para obtener valores futuros de la variable objeto de estudio. Las predicciones obtenidas pueden ser de dos tipos: puntuales o por intervalos. La predicción puntual se obtiene calculando el valor esperado de la variable en el período futuro $T + l$ condicionado al conjunto de información disponible hasta el período T . Y la predicción por intervalos, para un nivel de confianza del 95 por ciento, se obtiene sumando y restando a la predicción puntual la desviación típica del error de predicción multiplicada por el valor tabulado para el 95 por ciento de confianza.

III. RESULTADOS

III-A. Primer resultado

Como primer resultado gas6677.dat contiene datos mensuales del consumo de gasolina en España entre Enero de 1966 y agosto de 1977. Utilizaremos el lenguaje de programación R, el código desarrollado en este primer resultado está disponible en: <https://github.com/Eduar-Amaya/PoliticaMonetaria.git>

Haciendo un Análisis de Series Temporales vamos hacer una predicción de cómo será el consumo de gasolina en España a partir del mes de Septiembre de 1977 a Junio de 1978.

Vamos a ajustar un modelo ARIMA, sin embargo muchos modelos de series temporales (ARIMA) se exige que las series sean estacionarias, es decir, sin componente de tendencia ni estacionalidad además que la variabilidad sea constante. En la figura 1 se aprecia que la serie presenta una tendencia ascendente (la serie no es estacionaria en media), con esto se puede afirmar que la serie no es estacionaria. También se puede apreciar que la serie no es estacionaria en cuanto a la varianza, ya que que hay variabilidad.




Figura 1. Gráfica de la Serie.

Primero necesitamos controlar la variabilidad (que sea constante) para ello aplicamos logaritmo como se observa en la figura 2, la variabilidad parece ser constante.




Figura 2. Variabilidad Estable.

Luego que la variabilidad es constante se procede a eliminar la tendencia y la estacionalidad, para ello se recomienda utilizar diferencias o logaritmos en este caso vamos a utilizar diferencias. En R las funciones *ndiffs* y *nsdiffs* nos dan el número de diferencias regulares y estacionales respectivamente que se necesita llevar a cabo para que la serie sea estacionaria. En R se hace de la siguiente manera:

```
> ndiffs(gas.ts)
[1] 1
> nsdiffs(gas.ts)
[1] 1
```

Significa que necesitamos diferenciar una vez para eliminar la tendencia y una vez para eliminar la estacionalidad. En la figura 3 se observa que no hay tendencia y en la figura 4 se muestra como la serie parece ser estacionaria luego que se haya eliminado la componente estacional.




Figura 3. Serie Diferenciada una vez.




Figura 4. Serie Diferenciada dos veces.

Para comprobar que la serie es estacionaria utilizaremos el Test de Dickey-Fuller con $\alpha = 0,05$

- H_0 : La serie no es estacionaria. Si $p > 0,05$
- H_1 : La serie es estacionaria. Si $p < 0,05$

Acontinuación se muestra como se hace en R:

```
> adf <- adf.test(dif2_gas.ts)
> adf$p.value
[1] 0.01
```

El valor $p = 0,01$ del test nos indica que se puede rechazar la hipótesis nula H_0 , es decir, se acepta la hipótesis alternativa H_1 . Por lo tanto la serie es estacionaria.

Las figuras 5 y 6 nos indican el número de medias móviles y autoregresivos respectivamente para determinar el proceso ARIMA(p,d,q) más adecuado que haya podido generar la serie estacionaria.




Figura 5. Determina el numero de medias móviles




Figura 6. Determina el numero de Autoregresivos

Identificación del Modelo

Observando las figuras 5 y 6 podemos plantear varios modelos para el análisis de la serie como ser: $ARIMA(2, 0, 2)(0, 1, 2)$, $ARIMA(2, 0, 2)(2, 1, 2)$, $ARIMA(2, 1, 2)(0, 1, 2)$, incluso $ARIMA(2, 1, 2)(2, 1, 2)$, etc.

En las tablas I y II se puede apreciar que los ajustes que mejor AIC (Criterio de Información Akaike) y BIC (Criterio de Información Bayesiano) tienen dos autoregresivos, una diferencia y dos medias móviles; en la parte estacional cero autoregresivos, una diferencia y dos medias móviles. Siendo $ARIMA(2,1,2)(0,1,2)$ el modelo que los tests arrojan con menor valor y por tanto con mayor consideración. Una vez estimados los modelos y elegido el mejor de ellos, procedemos a la validación del modelo.

Modelos	df	AIC
arima1	7	1058.460
arima2	9	1054.405
arima3	7	1046.801
arima4	9	1046.542

Cuadro I
CRITERIO AIC

Modelos	df	BIC
arima1	7	1078.424
arima2	9	1080.073
arima3	7	1066.711
arima4	9	1072.139

Cuadro II
CRITERIO BIC

Validación

En las figuras 7 y 8 podemos apreciar que no hay ningún rezago significativo (aparte del 0 que por definición es 1) que denote ningún tipo de estructura. Por tanto podemos decir que los residuos son ruido Blanco.




Figura 7. Función de Autocorrelación




Figura 8. Función de Autocorrelación Parcial

En la figura 9 vemos el diagnóstico de nuestro modelo si es bueno, o no, la primera imagen corresponde a los errores estandarizados los cuales deben parecerse mucho al ruido blanco. La imagen 3 corresponde a los valores p del estadístico de Ljung-Box, donde la línea punteada de color azul es la significancia de $\alpha = 0,05$




Figura 9. Diagnóstico

Para comprobar que los residuos son ruido blanco vamos a utilizar el Test de Ljung-Box para Ruido Blanco con $\alpha = 0,05$:

- H_0 : Ruido blanco si $p > 0,05$
- H_1 : No hay ruido blanco si $p < 0,05$

A continuación se muestra cómo se hace en R

```
> lb <- Box.test(arima3$residuals,
  type = "Ljung-Box")
> lb$p.value
[1] 0.9169298
```

El valor $p = 0,9169298$ del test nos indica que se acepta la hipótesis nula H_0 , es decir, que hay ruido blanco. Por tanto el modelo se ajusta bien, que el modelo se ajusta significa que tiene media igual a cero, varianza constante y que los errores están serialmente correlacionados.

Vamos a corroborar graficando el error cómo se muestra en la figura 10 que el error tiene media igual a cero. Por tanto validamos nuestro modelo, implica que podemos hacer las predicciones.




Figura 10. Gráfica del Error

Predicción:

Queremos saber cómo será el consumo de gasolina en España en los 10 meses siguientes. En la tabla III se observa los valores y en la figura 11 se observa su comportamiento.

Meses	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Sep 1977	451.3333	433.2431	469.4235	423.6668	478.9999
Oct 1977	420.3339	401.8497	438.8180	392.0648	448.6029
Nov 1977	389.7801	368.9515	410.6087	357.9256	421.6346
Dec 1977	426.9398	405.7897	448.0899	394.5935	459.2861
Jan 1978	396.3406	374.4069	418.2743	362.7959	429.8853
Feb 1978	374.9805	352.7951	397.1660	341.0508	408.9103
Mar 1978	419.6776	397.1171	442.2382	385.1743	454.1810
Apr 1978	442.3261	419.5602	465.0920	407.5086	477.1436
May 1978	433.6475	410.6419	456.6531	398.4635	468.8316
Jun 1978	456.6717	433.4881	479.8552	421.2155	492.1278

Cuadro III
PREDICCIONES




Figura 11. Gráfica de las Predicciones

Para el mes de Septiembre de 1977 el consumo será de 451.333, con un intervalo de confianza de 95 por ciento el consumo estará entre 423,6668 – 478,9999 y así sucesivamente para los otros meses. Recordemos que estos datos son de Enero de 1966 y agosto de 1977, si estos datos fueran mas actuales los resultados serían diferentes, esto por el crecimiento poblacional o por el precio de la gasolina.

DISPONIBILIDAD DE DATOS

Los datos utilizados están disponibles en <http://verso.mat.uam.es/joser.berrendero/datos/gas6677.dat>.

REFERENCIAS

- [1] Peña, D. (2005)). *Análisis de series temporales*. Alianza Editorial.
- [2] José Alberto Mauricio, *Introducción al Análisis de Series Temporales*, Universidad Complutense de Madrid.
- [3] Brockwell, P.J. Y Davis, R.A (2002)., *Introduction to Time Series and Forecasting 2ª edition*, Springer.
- [4] James H. Stock, Mark W. Watson, *Introducción a la Econometría*.
- [5] Theil, H., *Principles of Econometrics*, John Wiley and Sons, Inc., New York, 1971
- [6] <https://github.com/Eduar-Amaya/PoliticaMonetaria.git>